

Corrigé – Recherche textuelle : algorithme de Boyer-Moore

Exercice 1

1. La séquence s'arrête à l'indice $n-1$, mais puisqu'on cherche la correspondance du motif en entier, on peut s'arrêter à l'indice $n-m-1$.
2. j stocke le nombre de caractères qui coïncident entre S et M , à une position i donnée, en commençant par la gauche de M .
3. Deux cas sont possibles : à la fin de la boucle bornée, c'est-à-dire lorsqu'on a parcouru toute la séquence sans trouver le motif, ou bien lorsqu'on le trouve : on est dans ce cas lorsque j vaut m .

Exercice 2

1. On commence par comparer le dernier caractère du motif, puis l'avant-dernier, etc.
2. Lorsque qu'on arrive à un caractère dans la séquence qui ne coïncide pas avec caractère du motif à la même position.
3. Si l'élément de la séquence n'est pas dans le motif, on décale le motif à la position de l'élément de la séquence + 1.

Si l'élément de la séquence considéré est à une autre place dans le motif, on décale le motif de manière à le faire coïncider avec ce caractère de la séquence, en prenant le caractère du motif le plus à droite possible, mais sans le faire revenir en arrière.

Exercice 3

VOICI UN SIMPLE EXEMPLE
EXEMPLE
-> NON
U/E ko et U n'est pas dans le motif donc on place le motif après U

VOICI UN SIMPLE EXEMPLE
EXEMPLE
-> NON
L/E ko mais L dans motif donc on les aligne

VOICI UN SIMPLE EXEMPLE
EXEMPLE
-> NON
I/E ko et I pas dans le motif donc on place le motif après I

VOICI UN SIMPLE EXEMPLE
EXEMPLE
-> NON
E/X ko mais X dans le motif donc on les aligne

VOICI UN SIMPLE EXEMPLE
EXEMPLE
-> OUI !

Implémentation Python

1. (a) 0134

(b)

```
def calcule_table_derniere_occurrence(chaine):  
    table_derniere_occurrence = {}  
    for j in range(len(chaine)):  
        table_derniere_occurrence[chaine[j]] = j  
    return table_derniere_occurrence
```

(c)

```
assert calcule_table_derniere_occurrence("HELLO") == {"H": 0, "E": 1, "L": 3,  
    ↪ "O": 4}
```

Test de la correspondance

1. Compléter le pseudo-code suivant.

fonction correspondance(sequence, motif, i, table_derniere_occurrence)

Entrée:

- sequence: séquence (chaîne de caractères)
- motif: motif recherché (chaîne de caractères)
- idx_sequence: position actuelle dans le sequence, correspondant à la position du caractère le plus à gauche du motif (entier)
- table_derniere_occurrence: table de sauts (dictionnaire)

Sortie:

- decalage (entier) pour la prochaine étape, ou 0 si la correspondance a été trouvée

Pour idx_motif variant de l'indice du dernier caractère du motif au premier de manière décroissante:

lettre_sequence ← caractère à l'indice `idx_sequence + idx_motif` de sequence
si lettre_sequence est différent de la lettre à l'indice idx_motif:

si lettre_sequence n'est pas dans table_derniere_occurrence:

renvoyer l'indice suivant la position courante

renvoyer <la plus grande valeur entre l'indice de la dernière occurrence

de la lettre qui coïncide dans le motif et 1 (car on ne veut pas "reculer")

ex :

FTGAABCF

AXCA>

renvoyer <renvoyer 0 (on a trouvé la correspondance)>

2. Voir fichier Python

Tests

Voir fichier Python