

L'algorithme des k plus proches voisins

Capacités attendues

- ✓ Écrire un algorithme qui prédit la classe d'un élément en fonction de la classe majoritaire de ses k plus proches voisins.

1 Introduction

Nous allons travailler sur un algorithme d'apprentissage automatique, souvent appelé, algorithme de « machine learning ». L'idée est d'utiliser un grand nombre de données afin « d'apprendre à la machine » à résoudre un certain type de problème. Il s'agit d'un algorithme d'apprentissage automatique supervisé, c'est-à-dire que pour pouvoir apprendre, il a besoin d'un jeu de données qui va lui servir de référence.

Le terme de *machine learning* a été utilisé pour la première fois par l'informaticien américain Arthur Samuel (1901-1990) en 1959. Il est un pionnier américain de l'intelligence artificielle, du jeu sur ordinateur et du *machine learning* avec notamment son programme informatique de dames.

De nos jours, avec l'importance des données, ce type d'algorithme est très utilisé par les GAFAM (Google, Apple, Facebook, Amazon et Microsoft) afin par exemple de prévoir à ses clients des « suggestions d'achats » souvent très pertinentes.


2 Présentation

Nous allons étudier un algorithme d'apprentissage : l'algorithme des k plus proches voisins :


- On dispose de données classées par catégories.
- On rajoute une donnée.
- On lui donnera en sortie la catégorie majoritaire de ses k plus proches voisins.

Exemple :

On dispose de deux populations dont on connaît la localisation (coordonnées) et une caractéristique (Rouge ou Verte)



On rajoute un élément en précisant ses coordonnées et on lui impose la caractéristique (Rouge ou Verte) majoritaire parmi ses k plus proches voisins. Dans cet exemple, on a $k = 3$: le nouvel élément sera Rouge, car parmi ses 3 plus proches voisins, deux ont la caractéristique Rouge.



Le calcul de distance utilisé ici est la distance euclidienne.

Remarque : Toutes les données d'une même catégorie doivent être écrites dans un même format afin que l'algorithme soit efficace, sinon on peut obtenir des résultats faux ou du moins différents de ceux qui sont attendus. On parle de standardisation, ou de normalisation, des données

3 Un autre exemple

Considérons le jeu de données suivant :

Nom	Âge	Revenus (k€)	Nombre d'achats	Fidélité
Esmé	35	35	3	N
Chiara	22	50	2	O
Nadim	63	200	1	N
Aveli	59	170	1	N
Mohamed	25	40	4	O

Ce tableau présente l'âge, le revenu, et le nombre d'achats d'un client et à partir de ces données on donne sa fidélité. Un nouveau client se présente et on souhaite estimer sa fidélité

Nom	Âge	Revenus (k€)	Nombre d'achats	Fidélité
Marie	25	50	2	???

Exercice 1

1. Calculer la distance de Marie avec chacun des autres clients. Par exemple :

$$d(\text{Marie}, \text{Esmé}) = \sqrt{(25 - 35)^2 + (50 - 35)^2 + (2 - 3)^2}.$$

2. Classer par ordre croissant les distances calculées.
3. Qui sont les trois plus proches voisins de David ?
4. Peut-on considérer David comme un client fidèle ?
5. Décrire le principe de l'algorithme

4 Traitement automatisées des données

Exercice 2 Compléter le Notebook sur Capytale.